國立東華大學資訊工程學系
National Dong Hwa University

113 學年度大學部畢業專題研究報告
113 CSIE Undergraduate Project Report

基於卷積神經網路之人臉辨識的 FPGA 硬體實現

指導教授 Advisor：紀新洲 教授

專題參與人員 Team Member: 王澤鈞

陳昱丞

張芷榆

陳品秀

中 華 民 國 1 1 4 年 5 月 2 0 日

摘要

關鍵字 Keywords：機器學習、卷積神經網路、人臉辨識、FPGA

本研究旨在建置一套臉部辨識系統，結合卷積神經網路與 PYNQ-Z1 嵌入式硬體平台，使系統能夠辨識使用者人臉，提升居家與商辦安全的實用性。使用者註冊時，透過連接至 PYNQ-Z1 的攝影機拍攝人臉影像，並由模型提取對應的 128 維特徵向量，這些特徵資料將儲存為文字格式檔案，以供後續比對使用。辨識階段中，系統同樣拍攝當前人臉影像並輸入模型，產生對應的特徵向量，接著與註冊資料庫中的向量進行餘弦相似度比對，根據比對結果判斷相似度是否超過設定閾值，進而決定是否成功解鎖。本研究期望在低成本、資源有限、以 FPGA 為運算加速器之 PYNQ-Z1 平台上，實現一套無需依賴雲端即可獨立運作的人臉辨識系統，涵蓋臉部註冊、特徵比對與門鎖控制的完整流程。

壹、前言

隨著人工智慧與物聯網(IoT)技術的快速發展，門禁系統已逐漸從傳統的鑰匙或 RFID 感應卡演進為更智慧化的生物辨識技術，如指紋、虹膜與臉部辨識。其中，臉部辨識技術因具備非接觸性、高便利性與相對安全等優勢，已廣泛應用於智慧建築、企業安防及智慧家居等領域。然而，現有的商業臉部辨識門禁系統往往價格昂貴，且對嵌入式硬體平台的適應性較低。因此，開發一套低成本、高效能、易部署且能離線獨立運作的人臉辨識系統，成為一項值得深入研究的課題。

本專題旨在開發一套基於卷積神經網路(Convolutional Neural Network, CNN)之人臉辨識系統，並部署於 PYNQ-Z1 FPGA 開發板上。使用者可透過鏡頭擷取臉部影像，在註冊階段，系統會將影像輸入預先訓練好的神經網路模型，轉換為 128 維特徵向量，並儲存為文字格式檔案。辨識階段則同樣擷取臉部影像，生成對應的特徵向量，並透過餘弦相似公式進行比對；若相似度高於預設門檻，則視為辨識成功。

選用 PYNQ-Z1 板作為部署平台的主要原因，在於其結合可編程邏輯(Programmable Logic)與處理系統(Processing System)的架構，能在有限空間內實現完整的人臉辨識功能，不僅加速模型推論，亦能將整體流程整合至單一裝置中，以達成低功耗、易部署的目標。

未來，本系統期望能導入效能更佳的 FPGA 開發板，以降低註冊階段攝影機畫面延遲，並實現辨識結果的即時螢幕輸出，無需使用者手動拍照截圖後再傳入辨識。同時也期望能擴充更多功能，保障居住者的居住安全。

貳、研究動機和研究問題

在現今科技日新月異的時代,「安全」已成為智慧生活中不可忽視的核心議題。除了網路資訊安全外，實體空間的出入控管與居住安全也備受關注。為了保障居住與商務安全，同時避免了目前商用臉部辨識的昂貴價格，再加上生物辨識技術的普及，臉部辨識因其直覺性、非接觸性與相對高的辨識率，逐漸取代傳統鑰匙與 RFID 感應卡，成為新一代門禁控制的首選技術。

然而，目前市面上的臉部辨識門禁系統大多價格昂貴，且多依賴雲端運算，無法脫離網路獨立運作，在隱私保護與成本效益方面皆存在限制。另一方面，欲將深度學習模型應用於一般嵌入式設備時，往往面臨算力不足與延遲過高的問題，使即時辨識效果大打折扣。

我們希望能結合深度學習與 FPGA 技術，打造一個具備註冊、辨識與控制功能且不仰賴雲端的完整人臉辨識系統，且可透過 FPGA 對模型進行加速，實現低成本、可攜式、辨識速度快且安全的智慧門禁解決方案。透過部署於 PYNQ-Z1 板上的硬體實作，希望提供一種可行的替代方案，降低進入門檻並提升智慧居住與商辦環境的安全性與便利性。

參、 研究方法和步驟

一、文獻探討

本研究住焦於清亮樺臉部辨識流水線(如下圖 1)：

臉部偵測→對其與前處理→特徵嵌入→相似度度量與閾值判定

選用 MobileFaceNet 作為嵌入模型，主因在於其以深度可分離捲機與輕量化瓶頸設計達到計算量與精度的平衡，適合於資源受限之邊緣裝置。

- 臉部偵測：比較 Haar、MTCNN 在召回率與誤檢上的差異。
- 特徵學習：對比 FaceNet/ArcFace 與 MobileFaceNet 的遷入為度與損失函數差異。
- 硬體對映：回顧 CNN 在 FPGA 上的常見最佳化，如 pipeline 和 array partition。

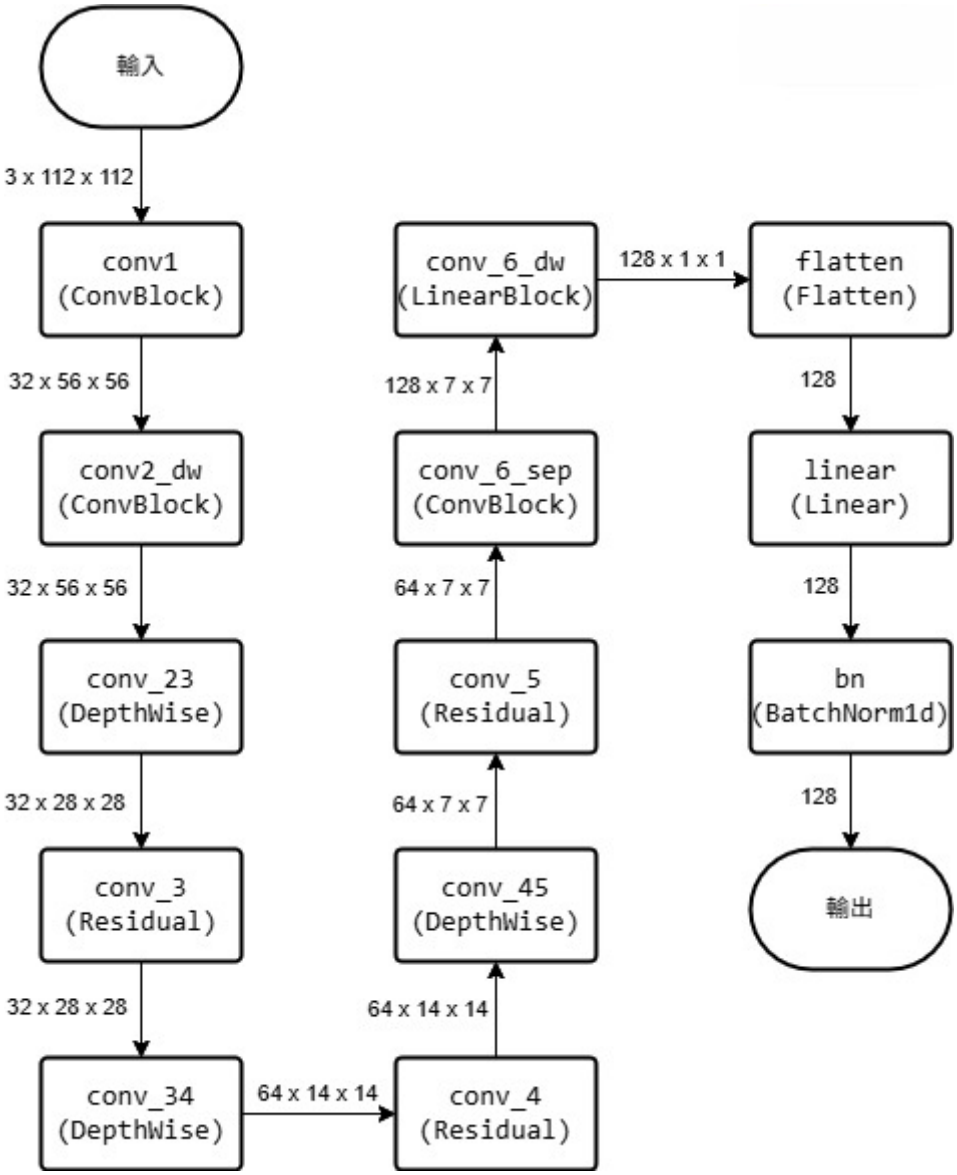

圖 1、MobileFaceNet 模型流程圖

二、訓練流程與模型架構

在每一個訓練批次(batch)中，系統首先從資料載入器中擷取一組人臉影像及其對應的標籤。這些影像經由 MobileFaceNet 模型進行前向傳播，產生每張人臉對應的嵌入特徵向量(feature embedding)，用以表徵其高維特徵資訊。接著，這些特徵向量會輸入 ArcNet ，透過 L2 正規化與角度 margin 技術計算帶有角度懲罰的分類 logits，以強化類內特徵一致性並擴大類間差異。隨後，將 logits 與真實標籤一併輸入 CrossEntropy Loss ，計算預測誤差。誤差經由反向傳播演算法轉換為梯度，並由優化器(如 SGD)依據這些梯度更新 MobileFaceNet 與 ArcNet 的模型參數，持續優化損失函數，逐步提升人臉辨識的準確率，如圖 2。

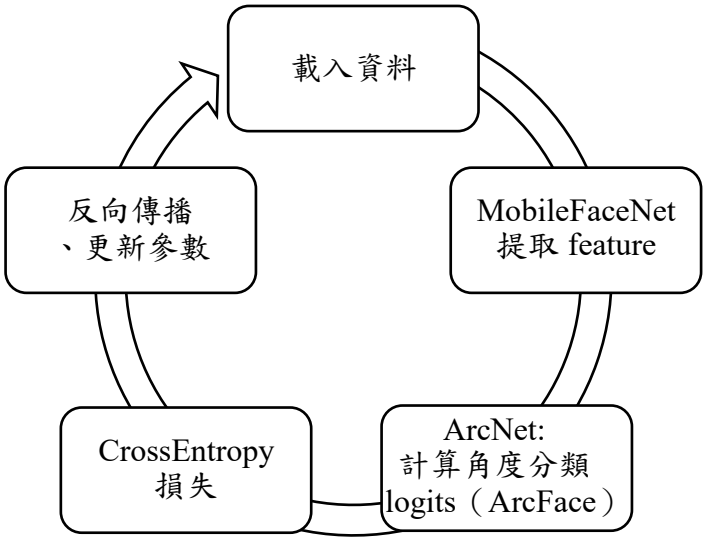

圖 2、訓練流程圖

三、PYNQ-Z1 系統與硬體設計

本系統以 PYNQ-Z1 為平台，採 **Processing System(PS)**與 **Programmable Logic(PL)**分工：PS 負責流程控制、影像擷取與檔案存取；PL 以硬體加速器承載卷積、BatchNorm、PReLU 等計算。兩者透過 **AXI** 匯流台交換資料，並以 **DMA** 進行大塊資料搬移以降低 CPU 介入與等待時間。各層運算以 **HLS 模組化**設計，餅以流程圖/權重忖取模式配置片上緩衝與 DDR，兼顧延遲與資源使用時間。

(1) Vitis HLS 與 Vivado 流程

以 **Vitis HLS** 將 C/C++ 撰寫之運算核心轉換為 RTL(Register Transfer Level)硬體描述，並套用 Loop pipeline、array partition 等最佳化以提升併行度。產出的 IP 由 Viavado 匯入置設計平台，整合 PS、AXI 互聯、DMA 與各運算模式，完成 Block Design→綜合/實作→產出 bitstream。最終由 PS 載入 bitstream，並以軟體 API 驅動 PL 端加速器執行推論，如圖 3。

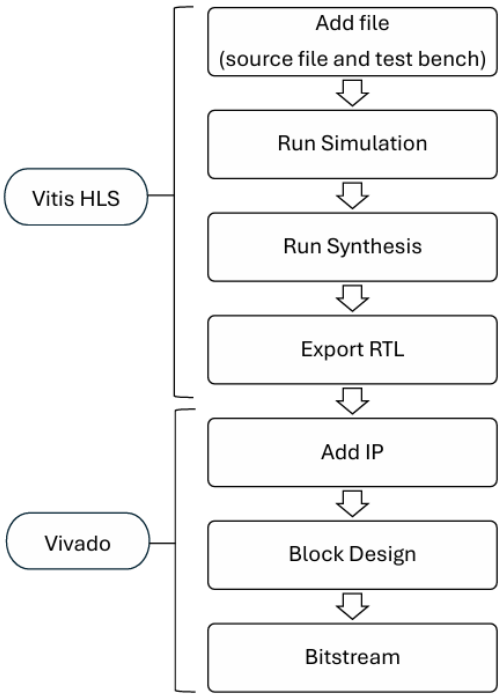

圖 3、Vitis HLS 和 Vivado 流程圖

(2) Vivado Block Design

在 **Block Design** 中，以 **ZYNQ PS** 微系統主控，**連結 AXI Interconnect 與 AXI DMA**，將各 HLS 運算 IP(如 Conv、BN、PRLU、Linear)以 **AXI4-Lite**(控制站存器)與 **AXI4-Stream**(資料流)介面串流。PS 端負責設定各 IP 參數、啟動 DMA 傳輸，並在運算完成後回收結果。此架構利於後續替換或新增層級模組，維持系統可維護性或擴充性，Block Design 如圖 4。

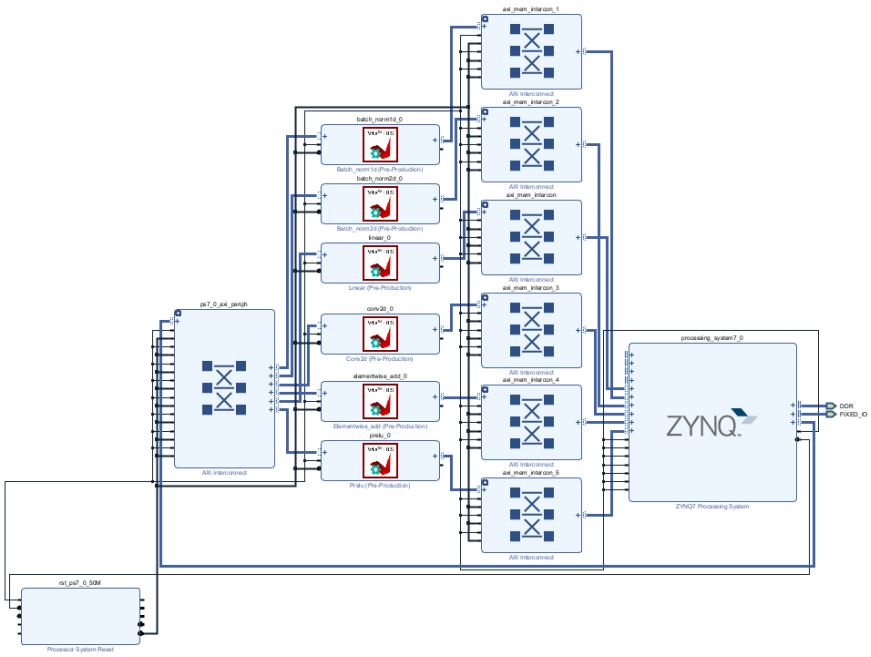

圖 4、Vivado 的 Block Design

(3) 整體系統流程

系統自鏡頭取得影響後，由 PS 完成必要前處理併觸發 PL 推論：影像→（偵測/對齊）→CNN 嵌入→產生 **128 維特徵向量**。註冊時將向量存入資料庫；辨識時計算與庫內向量之**餘弦相似度**，超過閾值及判定通過，由 PS 端控制輸出。此流程再**單機、低功耗**條件下完成，不依賴雲端，如圖 5。

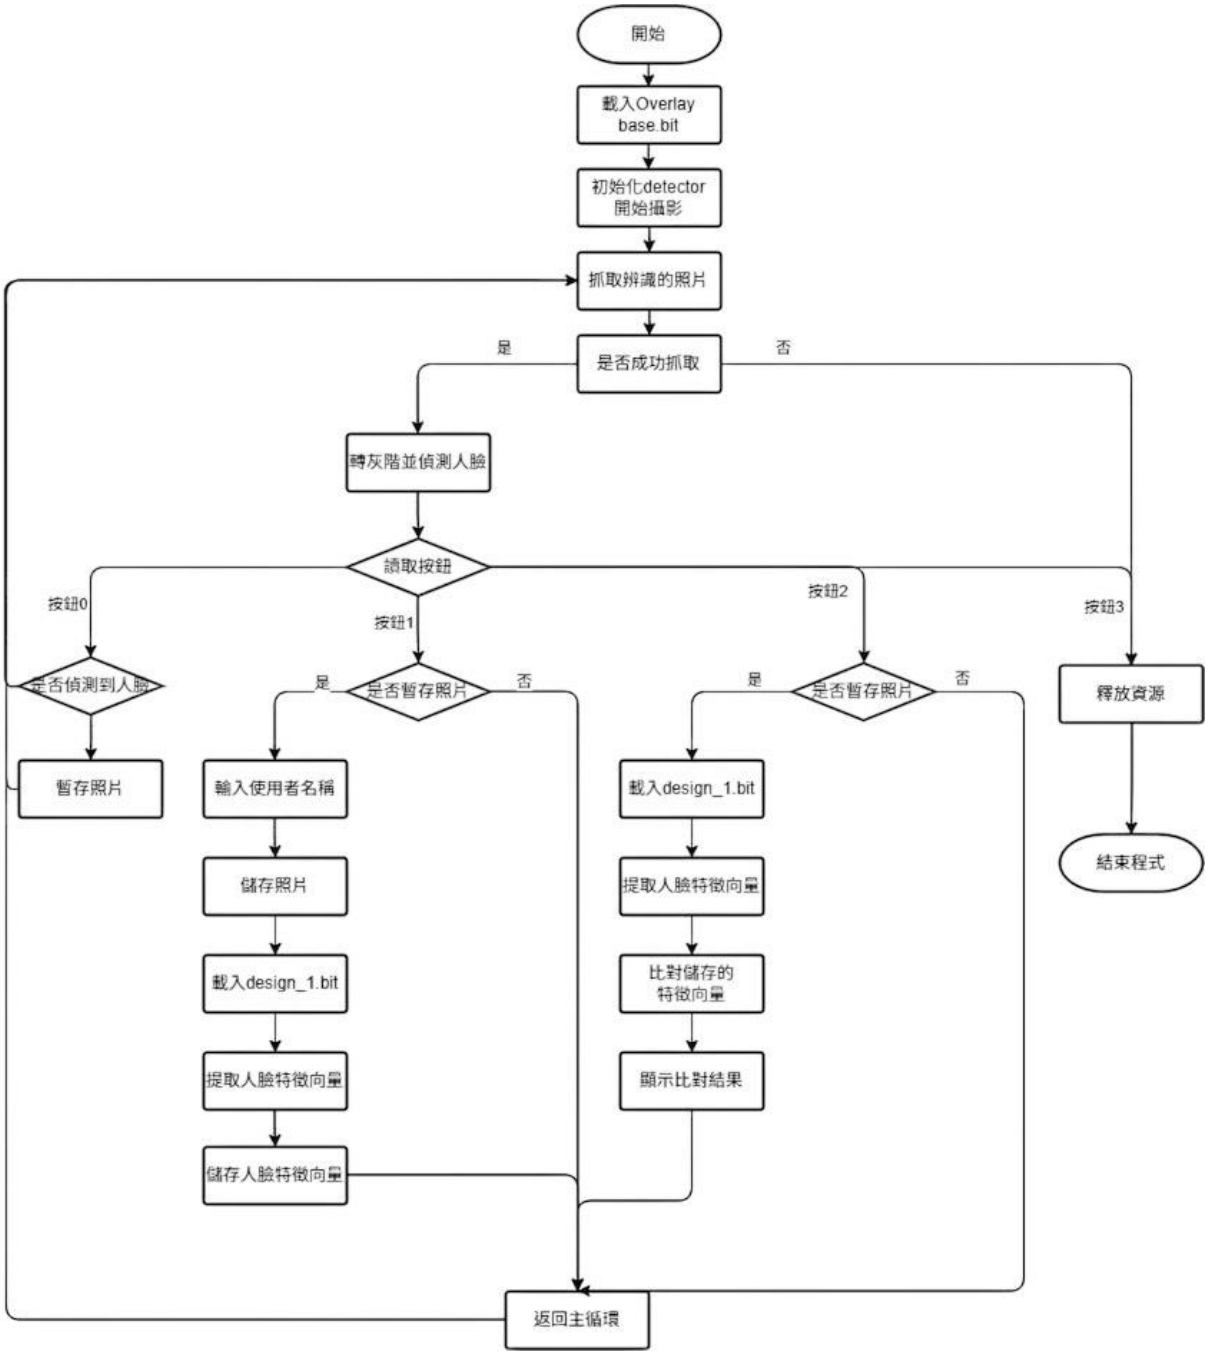

圖 5、整體辨識流程圖

肆、實驗結果與討論

一、臉部擷取品質比較

在系統開發過程中，我們比較了 MTCNN(Multi-task Cascaded Convolutional Networks)與 **Haar 特徵分類器**兩種人臉偵測方法。MTCNN 在複雜背景與光照條件下表現優異，召回率與精確度接顯著高於 Haar，但其網路結構較為龐大，推論延遲明顯過高，無法滿足嵌入是平台的即時需求，如圖 6。

```
=== 比對 MTCNN ground truth 的結果 ===
Precision: 0.9182
Recall:    0.8656
F1-score:  0.8911
```

圖 6、Haar 和 MTCNN 比對結果

相對的，**Haar 特徵分類器**演算法簡單、運算速度快，適合用在資源有限的 ARM CPU 上執行。雖然在光線或角度變化下可能出現漏檢與誤檢，但其低延遲特性使系統能及時擷取人臉，並將後續的特徵抽取交由 FPGA 部屬的 MobileFaceNet 完成。下圖 7、8 為訓練結果，綠色眶表示 MTCNN 偵測結果，紅色框則為 Haar 偵測結果，可清楚觀察兩者在上述情況下的差異。

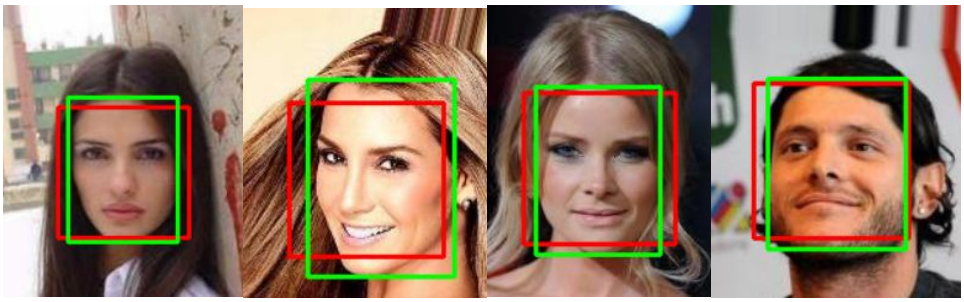

圖 7、Haar 和 MTCNN 擷取成功

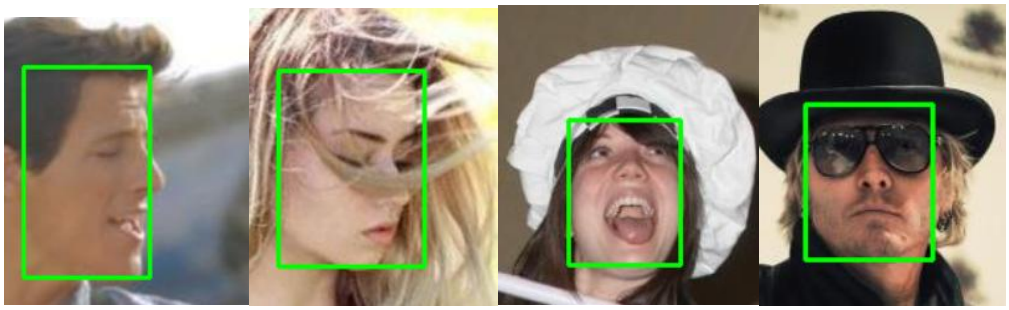

圖 8、Haar 擷取失敗 MTCNN 擷取成功

二、辨識準確度與 ROC

為探討特徵向量為度對人臉辨識效能的影響，本研究分別測試了 **512 維、256 維與 128 維**三種設定，並比較其 Accuracy、Precision、Recall 與 F1-score。

實驗結果顯示，**512 為模型**整體準確度較高(Accuracy≈0.8165)，Precision 與 Recall 均衡，適合對精確度要求較高的場景，如圖 9；在 Recall 部分，**256 維模型**的數值最低，表示該模型漏掉較多應該成功辨識的目標，可能是因為特徵維度過低，導致無法有效區分目標，如圖 10；**128 為模型**雖然在準確度與 Precision 略低(Accuracy≈0.7843)，但其特徵向量較短，運算與儲存效率明顯優於高維度模型，在嵌入式環境下更具實用性，如圖 11。

```
[MobileFaceNet_512] 準確度 (Accuracy): 0.8165
[MobileFaceNet_512] Precision: 0.8896
[MobileFaceNet_512] Recall:    0.7227
[MobileFaceNet_512] F1-score:  0.7975
```

圖 9、512 特徵數辨識指標結果

```
[MobileFaceNet_256] 準確度 (Accuracy): 0.7843
[MobileFaceNet_256] Precision: 0.8596
[MobileFaceNet_256] Recall:    0.6797
[MobileFaceNet_256] F1-score:  0.7591
```

圖 10、256 特徵數辨識指標結果

```
[MobileFaceNet_128] 準確度 (Accuracy): 0.7897
[MobileFaceNet_128] Precision: 0.8405
[MobileFaceNet_128] Recall:    0.7150
[MobileFaceNet_128] F1-score:  0.7727
```

圖 11、128 特徵數辨識指標結果

從 **ROC 曲線** 與 **AUC(Area Under Curve， ROC 曲線下的面積)**指標來看，三種模型的 AUC 皆高於 0.85，其中以 512 維模型(AUC≈0.8826)表現最佳，但 128 維(AUC≈0.8578)與 256 維(AUC≈0.858)也保持在相近水準。這顯示即使降低嵌入維度，系統仍然能維持良好的辨識能力，如圖 12。

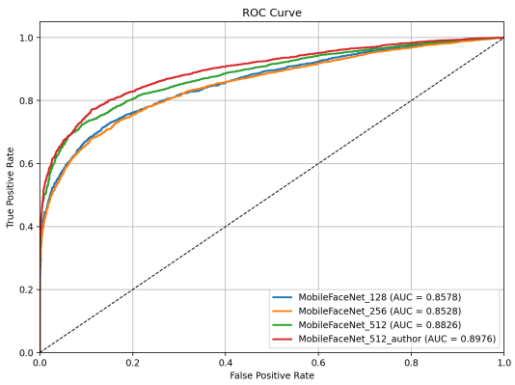

圖 12、ROC 曲線圖

接下來比較 512、256 和 128 維特徵數在**實際應用上(辨識時間)**的差異，進而決定最適合本專題使用的模型，結果如表 1 顯示。

辨識模型(特徵數)	辨識時間(秒)
512 個	81.38220
256 個	25.05328
128 個	19.36883

表 1、辨識時間比較

綜合比較三種不同特徵數的臉部辨識模型後發現，128 維特徵模型雖然特徵量較小，但辨識速度最快，特別適合用於資源有限或嵌入式等移動裝置上，因此本專題**最終選擇使用該 128 維特徵模型**。256 維特徵模型大小界在 128 和 512 之間，辨識速度也是在中間。至於 512 維特徵模型，雖然具備較強的細節捕捉能力，但辨識速度較慢、變數量多，較適合部署於運算效能較高的系統中。

三、辨識狀況

本部分在正常拍攝條件下，透過 Intra-class (同一人)與 Inter-class (不同人)相似度分析，評估各臉部辨識模型的辨識能力，結果以表 2 呈現。實驗設計如下：先為同一人儲存 15 張照片，另選取 15 位不同的人，各儲存 1 張照片。接著讓該位儲存 15 張照片的人進行辨識，記錄與自身及他人的相似度均值，並計算兩者之間的分離度，以判斷模型能否有效區分「同一人」與「不同人」的特徵差異，而不僅是單一比對分數的高低。

辨識模型(特徵數)	同一人相似度均值	不同人相似度均值	分離度(差值)
512 個	0.8860	0.2377	**0.6483**
256 個	0.8995	0.3002	0.5993
128 個	0.9124	0.3234	**0.5890**

表 2、Intra-class vs Inter-class

根據表 3 可知，分離度(Intra-class 與 Inter-class 相似度的差值)越大，表示模型在區分是否為同一人時的辨識效果越佳。從結果來看，512 特徵模型的分離度最高，顯示其具備最強的區別能力。這主要歸因於其特徵維度較高，能更細緻地刻畫人臉的特徵細節，因此在相似度的辨識上表現更優異。

四、極端狀況失敗與原因

這部分主要透過三套模型來分析辨識失敗的情況與原因。我們分別使用**「露牙齒笑」**、**「皺眉閉眼」及「臉部低下」**這三種特殊表情或姿態來進行註冊，並以同一位使用者的正常正臉照片作為辨識輸入，最後，根據相似度進行分析，以比較哪種註冊照片較不適合用於辨識(表 3)。

辨識模型(特徵數)	露牙齒笑	皺眉閉眼	臉部低下	正常正臉
512 個	0.67362	0.46773	0.58749	0.77967
256 個	0.60574	0.52276	0.44134	0.72450
128 個	0.65512	0.52847	0.51715	0.76816

表 3、極端辨識狀況比較(同個人的相似度)

根據表 3 可知，在極端特徵條件下，三種特徵模型對同一個人的相似度**普遍明顯下降**。在大幅表情變化(如露牙齒笑)時，128 與 512 特徵模型較能維持辨識能力，而 256 模型則較容易出錯。面對眼部異常(如皺眉或閉眼)時，**512 特徵模型因過度依賴細節(例如眼部輪廓)，導致特徵受干擾而表現較差**，反而特徵數較少的模型因特徵較模糊，能避免受到過多細節影響。在低頭情況下，三個模型的相似度皆下降，推測是因為低頭破壞了正臉的比例，特別是額頭與鼻樑等區域的結構變化，使得比對困難度上升。

五、HLS 優化

為了提升計算效率並降低運算延遲，針對模型中所有主要計算層進行優化。採用的優化策略包括：

- **循環管線化(Pipeline)**：在每一個時鐘週期中，交錯處理不同迴圈疊代的資料，使各運算步驟能並行執行。
- **陣列分割(Array Partition)**：每個分割區塊可同時讀取，有效降低存取壅塞，並提升記憶體頻寬利用率。

目的在於提升資料存取與運算效率，特別是在處理大規模輸入時，有助於整體性能評估與結果。在經管線化與陣列分割後，單次的推論時間由 20.6189 秒降至 19.3720 秒，**改善約 6.04%**，這也顯示能夠在不顯著增加資源的前提下有效壓縮延遲，如圖 13 與表 4。

```
model_origin running time:  20.61808967590332
model_opt running time:  19.3719699382782
optimize ratio:  6.04382 %
```

圖 13、128 特徵數辨識時間優化比對結果

資源項目	優化前	優化後	改善率
LUT	22.89%	26.66%	-3.77%
LUTRAM	5.75%	5.75%	0.00%
FF	19.17%	21.26%	-2.09%

BRAM	4.29%	4.29%	0.00%
DSP	16.36%	25.00%	-8.64%
BUFG	3.13%	3.13%	0.00%

表 4、整體硬體資源使用率

肆、結論與未來工作

本研究在 PYNQ-Z1 嵌入式開發板上成功實作一套可獨立運作的 CNN 人臉辨識系統。系統整合 Haar 特徵模型進行人臉偵測，並以 MobileFaceNet 為核心模型透過 128 維特徵向量達到擷取與辨識。系統具備拍照、註冊與辨識等操作，可於離線環境中完成及時人臉辨識展現低成本且高可攜性的智慧門禁應用潛力。

在設計上，透過 PL 與 PS 的協同與多個硬體加速模組的結合，有效改善了嵌入式平台常見的記憶體瓶頸。此外，我們亦設計了互動性強且直覺的操作流程，包含按鈕註冊與即時辨識功能，在有限硬體資源下實現操作簡便與高效能兼具的創新應用。

在未來希望能夠針對 Overlay 來去做優化，由於系統需交替執行攝影與辨識功能，因此需頻繁載入不同 Overlay ，導致 FPGA 內部邏輯反覆重建，造成時間延遲與整體效率下降。因此，未來若能整合兩個 .bit 檔合併為單一設計，便可大幅減少重複載入的時間成本，不過也可能因此導致資源緊繃，而無法成功合成。因此，亦可考慮採用雙 FPGA 架構，分別對應不同任務，當一塊板處理模型推論時，另一塊板則處理影像擷取，如此可有效提升系統並行性與總體效率。

除此之外，目前設計採用 FPGA design style ，其主要優點是設計流程彈性高、開發週期短，適合原型開發與功能驗證。但也是因為 FPGA 設計靈活且可重配置造成了他的效能在執行某些專項任務的效能會相對較低。然而， FPGA 為可重組邏輯，其通用性在執行專用任務時可能受限於資源利用率與時序效能。未來可考慮轉向 Standard Design Style ，即採用經優化的標準邏輯單元建構專用電路，以提升表現。

綜合而言，本專題展示 CNN 模型於 FPGA 上高效且可行的部署方式，具備良好的擴展性，未來可應用於智慧門禁、行動裝置與邊緣計算等多元場景。